

MO824 - Análise Comparativa entre as metaheurísticas *GRASP*, *Tabu*, e *GA* para a resolução do problema MAX-QBF com mochila

Lucas Guesser Targino da Silva (203534)

3 de julho de 2022

Esse trabalho tem como objetivo comparar os resultados obtidos pelas implementações de três metaheurísticas:

1. *Greedy Randomized Adaptive Search Procedure (GRASP)* [1]
2. *Tabu Search (Tabu)* [2]
3. *GA Algorithm (GA)* [3]

O problema resolvido foi o *MAX-QBF com mochila*, descrito no Apêndice A.

1 Metaheurísticas

Nessa seção são descritas todas as metaheurísticas utilizadas ao longo do trabalho.

No desenvolvimento dos trabalhos anteriores, explorou-se variações de cada metaheurística, essas com diferentes parâmetros, estratégias construtivas, buscas locais, etc. Para cada metaheurística, foram selecionadas duas variações, as que apresentaram melhor desempenho, para serem utilizadas nas investigações deste trabalho.

1.1 *GRASP*

A metaheurística *GRASP* é descrita no Algoritmo 1, sua estratégia construtiva em Algoritmo 2, e sua estratégia de busca local em Algoritmo 3, todos descritos no Apêndice A.2.

Ambas usam a estratégia construtiva padrão (Algoritmo 2) e o parâmetro α com valor 0.2.

Elas diferem na estratégia de busca local, entretanto. A primeira variação, chamada *GRASP Best*, utiliza *Best Improving*, em que toda a vizinhança é percorrida e a melhor opção selecionada. A segunda variação, chamada *GRASP First*, utiliza *First Improving*, em que a busca na vizinhança retorna a primeira solução encontrada que seja melhor do que a atual.

Em ambas, *Best Improving* e *First Improving*, a vizinhança é definida como o conjunto de soluções obtidas a partir da solução atual que tenham:

1. 1 elemento a mais - adição;
2. 1 elemento a menos - remoção;
3. 1 elemento trocado (equivalente a uma adição e uma remoção) - troca;

1.1.1 *GRASP Best*

1. Estratégia construtiva: **padrão** com α igual a **0.2**
2. Estratégia de busca local: **best improving**

1.1.2 *GRASP First*

1. Estratégia construtiva: **padrão** com α igual a **0.2**
2. Estratégia de busca local: **first improving**

1.2 *Tabu*

A metaheurística *Tabu* é descrita no Algoritmo 4.

Ambas as variações descritas nessa subseção usam:

1. solução inicial a solução da estratégia construtiva do *GRASP*, Algoritmo 2;
2. busca local *Best Improving*. Ela é similar a *Best Improving* descrita na Subseção 1.1, entretanto ela não considera a adição ou remoção de elementos que estão na lista tabu T (a menos que eles levem a uma solução melhor do que S^*);
3. *Tenure Ration*, parâmetro que controla o tamanho da lista tabu T , igual a 0.4, o que significa que T pode ter tamanho até 40% do tamanho da entrada.

A primeira variação, chamada *Tabu Vanilla*, implementa *Tabu* com as características acima. A segunda variação, chamada *Tabu com Intensificação e Diversificação*, inclui estratégias de diversificação e intensificação, descritas nas Subsubseção 1.2.1 e Subsubseção 1.2.2.

1.2.1 **Estratégia de Intensificação**

A estratégia de intensificação aumenta o tamanho da vizinhança, ao invés de considerar 1 adição, 1 remoção e 1 troca, ela considera:

1. 2 adições e 1 remoção;
2. 2 remoções e 1 adição;
3. 2 adições e 2 remoções;

A intensificação é feita em torno da melhor solução conhecida. Ela é ativada quando passam-se muitas iterações (o critério de parada é definido como um número máximo de iterações, e “muitas iterações” significa 20% número máximo de iterações) sem melhora na solução ótima e sem sua ativação.

1.2.2 **Estratégia de Diversificação**

A estratégia de diversificação constroi uma nova solução, utilizando a estratégia construtiva do *GRASP*, e recomeça a busca nesse outro local do espaço de solução. Além disso, antes de começar a busca, faz-se uma busca intensiva (usando a estratégia de intensificação) em torno dessa nova solução.

Seu critério de ativação é o mesmo da Estratégia de Intensificação, excetuando-se que Diversificação é ativada apenas quando Intensificação não é (no programa, há um registro separado para quando cada uma delas foi ativada pela última vez).

Assim, quando se passaram muitas iterações sem melhora na solução ótima, primeiro tenta-se intensificação. Caso essa falhe, executa-se a diversificação.

1.2.3 *Tabu Vanilla*

1. Solução inicial: saída da estratégia construtiva do *GRASP*
2. *Tenure Ration*: **0.4**
3. Estratégia de busca local: ***Best Improving***

1.2.4 *Tabu com Intensificação e Diversificação*

1. Solução inicial: saída da estratégia construtiva do *GRASP*
2. *Tenure Ration*: **0.4**
3. Estratégia de busca local: ***Best Improving***
4. Adição das estratégias: **Intensificação e Diversificação**

1.3 *GA*

A metaheurística *Tabu* é descrita no Algoritmo 5.

Ambas as variações descritas nessa subseção usam:

1. população inicial aleatória;
2. tamanho da população igual a 100;
3. seleção para reprodução em torneio: dois cromossomos são escolhidos aleatoriamente e o melhor dos dois (em relação à função de aptidão) é escolhido para continuar enquanto o outro é descartado.
4. reprodução com *two point crossover* ($2X$);
5. Critério de parada: 1000 gerações;

1.3.1 *GA Vanilla*

A primeira variação, chamada *GA Vanilla*, implementa *GA* conforme descrito na Subseção 1.3 com as seguintes adições/modificações:

1. taxa de mutação igual a 0.5%;
2. seleção da nova população: descendentes, substituindo-se o pior deles pelo melhor gene conhecido

1.3.2 *GA Steady*

A segunda variação, chamada *GA Steady*, implementa *GA* conforme descrito na Subseção 1.3 com as seguintes adições/modificações:

1. taxa de mutação igual a 1%;
2. seleção da nova população: os 100 melhores genes entre mães e filhos (conhecida como *Steady-State $\lambda + \mu$*);

Referências

- [1] M. G. Resende and C. C. Ribeiro, “Greedy randomized adaptive search procedures: advances and extensions,” in *Handbook of metaheuristics*, pp. 169–220, Springer, 2019.
- [2] M. Gendreau and J.-Y. Potvin, “Tabu search,” in *Handbook of Metaheuristics* (M. Gendreau and J.-Y. Potvin, eds.), vol. 146 of *International Series in Operations Research & Management Science*, ch. 2, pp. 41–56, Springer Science+Business Media, 2010.
- [3] C. R. Reeves, “Genetic algorithms,” in *Handbook of metaheuristics*, pp. 109–139, Springer, 2010.
- [4] G. Kochenberger, J.-K. Hao, F. Glover, M. Lewis, Z. Lü, H. Wang, and Y. Wang, “The unconstrained binary quadratic programming problem: a survey,” *Journal of combinatorial optimization*, vol. 28, no. 1, pp. 58–81, 2014.
- [5] L. G. T. da Silva, “Mo824a-combinatorial-optimization,” 2022. Disponível em <https://github.com/lucasguesserts/M0824A-combinatorial-optimization>.

Apêndice A *MAX-QBF com mochila* (MAX-KQBF)

Definição 1 (Conjunto Binário). $\mathbb{B} = \{0, 1\}$

Definição 2 (Função Binária Quadrática (QBF)). É uma função $f : \mathbb{B}^n \rightarrow \mathbb{Z}$ da forma:

$$f(x) = \sum_{j=1}^n x_i \cdot a_{i,j} \cdot x_j = x^T \cdot A \cdot x$$

em que $a_{i,j} \in \mathbb{Z}$, $\forall i, j \in \{1, \dots, n\}$ e A é a matriz n por n induzida pelos $a_{i,j}$.

Definição 3 (Problema de Maximização de uma Função Binária Quadrática (MAX-QBF)). Dada uma QBF f , um MAX-QBF é um problema da forma:

$$\max_x f(x)$$

Fato 1. MAX-QBF é NP-difícil [4]

Definição 4 (Maximum knapsack quadratic binary function (MAX-KQBF)). Dada uma QBF f , um vetor $w \in \mathbb{Z}^n$, e um valor $W \in \mathbb{Z}$, um MAX-KQBF é um problema da forma:

$$\begin{aligned} \max \quad & f(x) \\ \text{subjected to} \quad & w^T x \leq W \\ & x \in \mathbb{B}^n \end{aligned}$$

A.1 Instâncias

Foram utilizadas as instâncias com características conforme a Tabela 1.

| Instância | Num. Variáveis | Num. Possibilidades | Intervalo de Otimalidade |
|-----------|----------------|---------------------|--------------------------|
| kqbf020 | 20 | 1.0e+06 | [80, 151] |
| kqbf040 | 40 | 1.1e+12 | [275, 429] |
| kqbf060 | 60 | 1.2e+18 | [446, 576] |
| kqbf080 | 80 | 1.2e+24 | [729, 1000] |
| kqbf100 | 100 | 1.3e+30 | [851, 1539] |
| kqbf200 | 200 | 1.6e+60 | [3597, 5826] |
| kqbf400 | 400 | 2.6e+120 | [10846, 16625] |

Tabela 1: Instâncias do problema MAX-KQBF. Os dados completos estão disponíveis em [5].

A.2 GRASP

Algorithm 1 GRASP

```

1:  $S_{\text{best}} \leftarrow \emptyset$ 
2: for  $k = 1, \dots, N_{it}$  do
3:    $S \leftarrow \text{Greedy-Randomized-Construction}()$ 
4:    $S \leftarrow \text{Local-Search}(S)$ 
5:    $S_{\text{best}} \leftarrow \max \{S, S_{\text{best}}\}$ 
6: return  $S_{\text{best}}$ 

```

Algorithm 2 Greedy-Randomized-Construction(α)

```

1:  $S \leftarrow \emptyset$ 
2:  $C \leftarrow E$  ▷ Candidates list
3: for  $e \in C$  do
4:    $c(e) \leftarrow \text{Incremental-Cost}(e, S)$  ▷ Increment in the cost by adding  $e$  to  $S$ 
5: while  $C \neq \emptyset$  do
6:    $c_{\min} = \min \{c(e) : e \in C\}$ 
7:    $c_{\max} = \max \{c(e) : e \in C\}$ 
8:    $R \leftarrow \{e \in C : c(e) \leq c_{\min} + \alpha(c_{\max} - c_{\min})\}$  ▷ Restricted candidates list
9:    $s \leftarrow \text{Select-Random-Element}(R)$ 
10:   $S \leftarrow S \cup \{s\}$ 
11:  Update  $C$ 
12:  Update  $c(e)$ 
13: return  $S$ 

```

Algorithm 3 Local-Search(S)

```

1: while  $S$  is not local optimal do
2:    $S' \leftarrow \arg \max_{S' \in N(S)} \{f(S')\}$  ▷  $N(S)$  is the neighborhood of  $S$  ▷  $f$  is the goal function
3: return  $S$ 

```

A.3 Tabu

Algorithm 4 *Tabu* (S_0)

```
1:  $S \leftarrow S_0$  ▷  $S_0$  is the initial solution ▷  $S$  is the current solution  
2:  $S^* \leftarrow S$  ▷  $S^*$  is the current best solution  
3:  $f^* \leftarrow f(S^*)$  ▷  $f$  is the goal function  
4:  $T \leftarrow \emptyset$  ▷  $T$  is the tabu list  
5: while not Termination-Criteria-Satisfied do  
6:    $S \leftarrow \arg \max_{S' \in N(S,T)} \{f(S')\}$  ▷  $N(S,T)$  is the neighborhood of  $S$  limited by  $T$   
7:   if  $f(S) > f^*$  then  
8:      $S^* \leftarrow S$   
9:      $f^* \leftarrow f(S)$   
10:   Update  $T$  ▷ record moves and delete old entries  
11: return  $S^*$ 
```

A.4 GA

Algorithm 5 *GA*

```
1: escolher a população inicial de cromossomos  
2: while condição de parada não é satisfeita do  
3:   while Não há descendentes suficientes do  
4:     if condição de cruzamento é satisfeita then  
5:       Selecionar cromossomos mãe  
6:       Selecionar parâmetros de cruzamento  
7:       Executar cruzamento  
8:     if condição de mutação é satisfeita then  
9:       Selecionar pontos de mutação  
10:      Executar mutação  
11:    Calcular adaptação (fitness) dos descendentes  
12:  Selecionar nova população  
13: return Melhor cromossomo da população
```

Apêndice B Implementação e execução dos experimentos

O programs foram executados num ideapad S145 81S90005BR: Lenovo IdeaPad S145 Notebook Intel Core i5-8265U (6MB Cache, 1.6GHz, 8 cores), 8GB DDR4-SDRAM, 460 GB SSD, Intel UHD Graphics 620 no ambiente:

1. sistema operacional: Fedora 35
2. Java versão 17
3. Gradle versão 7.4

O desenvolvimento da solução do problema foi feito em Java, baseado nos frameworks disponibilizados pelos professores. O código pode ser encontrado em [5].